


Говорящий арт-объект: план реализации

Основа: концепция «ART / VOICE. Говорящий арт-объект» от 15.09.2026. Задача: зеркальная скульптура разговаривает с посетителями голосом, рассказывает о себе, об авторе и о парке и держит заданный образ.

1. Что строим (MVP)

Режим: один посетитель или одна группа, кнопка «Задать вопрос» (push-to-talk). Кнопка на улице надёжнее постоянного прослушивания: музыка, прохожие и соседние разговоры не запускают объект.


Сценарий:



Критерии готовности MVP:

- от окончания вопроса до первого звука ответа не больше 2,5 с (p90);
- ответ длится 10–25 с, 1–4 предложения, персонаж не выходит из образа;
- без интернета объект произносит заранее записанные реплики и не зависает;
- после перезагрузки или сбоя объект сам возвращается в работу меньше чем за 60 с;
- расход на ИИ-сервисы не выходит за дневной лимит.

2. Архитектура



* OpenAI Realtime API как альтернатива, если для площадки доступны сервис и оплата. Для Крыма и РФ по умолчанию берём Yandex (и GigaChat как запасной LLM). Провайдеры спрятаны за интерфейсами, поэтому замена сводится к правке конфигурации.

Ключевые решения

Вопрос	Решение	Почему
Конвейер	STT → LLM → TTS (каскад)	Каждый шаг контролируется, есть выбор провайдеров, дешевле Realtime, доступно в РФ
Задержка	Потоковое распознавание, стриминг токенов LLM, синтез по первому предложению	Первый звук через ~1,5-2,5 с вместо 4-6 с
Эхо	В MVP полудуплекс: пока объект говорит, микрофон закрыт	Эхоподавление нужно только для перебиваний (этап 2)
Кнопка/свет	Отдельный ESP32	Мини-ПК без GPIO; контроллер держит свет, даже когда ПК перегружается
Датчик присутствия	mmWave (LD2410), а не PIR	PIR на улице ловит солнце и нагрев металла
База знаний	Целиком в системном промпте (если меньше ~15-20 страниц)	RAG на старте не нужен; позже можно добавить поиск по фрагментам
Хранение	Только текст диалогов, аудио не пишем	Меньше рисков по 152-ФЗ; табличка «объект слушает, только по кнопке»

3. Программная часть: структура репозитория

```

talking-art/
├── voice_core/
│   ├── main.py          # запуск, сборка зависимостей
│   ├── state_machine.py # состояния и переходы, таймауты
│   ├── audio/{input,output,vad}.py
│   ├── providers/
│   │   ├── stt/{base,yandex}.py
│   │   ├── llm/{base,yandexgpt,gigachat,openai}.py
│   │   └── tts/{base,yandex}.py
│   ├── brain/
│   │   ├── persona.py    # сборка системного промпта
│   │   ├── session.py    # память беседы, сброс
│   │   └── guardrails.py  # запретные темы, длина, фильтр мата, отказ «в образе»
│   ├── hardware/serial_link.py
│   ├── fallback.py
│   └── budget.py         # счётчик расходов, дневной лимит
├── admin/                # FastAPI + шаблоны/HTMX
├── firmware/esp32/       # PlatformIO: кнопка, датчик, LED
├── content/
│   ├── persona.yaml      # имя, характер, манера речи, примеры ответов
│   ├── knowledge.md       # об объекте, авторе, парке
│   └── fallback/*.wav     # офлайн-реплики
├── deploy/               # systemd-юниты, install.sh, конфиг ALSA/PipeWire
├── tests/                # юнит-тесты + прогон сценариев без звука
└── config.example.yaml
```

Модули и требования

1. **State machine.** Явные состояния, таймауты (приветствие не чаще раза в 60 с, сброс беседы через 30–45 с без присутствия, максимум 15 с записи), обработка ошибок на каждом шаге с переходом в fallback.
2. **Audio.** Запись 16 кГц, моно. VAD обрезает тишину и завершает запись, если кнопку держат дольше, чем говорят. Автоматическая регулировка громкости по расписанию (днём громче, вечером тише).
3. **STT.** Поточковый gRPC SpeechKit v3, язык ru-RU, подсказки со словами-терминами (имя автора, названия парка) для лучшего распознавания.
4. **Brain.**
 - Промпт персонажа: имя, характер, манера речи, правила («отвечай 1–4 предложениями», «не выходи из образа», «на провокации отвечай шуткой и возвращай разговор к искусству»).
 - Память: последние 6–10 реплик текущей беседы.
 - Guardrails: список запретных тем (политика, религия, медицина, 18+), фильтр входа и выхода, отказ формулируется в образе.
 - Стриминг ответа по предложениям в TTS.
5. **TTS.** SpeechKit: выбрать голос и роль под характер, тонкая настройка скорости и интонации. Кэш частых фраз (приветствия, отказы) в WAV.
6. **Fallback.** Нет сети, таймаут провайдера или лимит исчерпан: объект проигрывает случайную из заготовленных реплик («Я задумался... спроси меня чуть позже»).
7. **Budget.** Учёт секунд STT, символов TTS и токенов LLM; дневной и месячный лимит; при превышении объект переходит в офлайн-режим, администратору уходит оповещение.
8. **Admin-панель.** Настройки голоса, громкости и расписания работы; редактор персонажа и базы знаний с кнопкой «проверить ответ» (текстовый чат); журнал диалогов; расходы; статус (сеть, микрофон, контроллер); перезапуск.
9. **Надёжность.** systemd Restart=always и watchdog, аппаратный watchdog на ESP32 (если ПК молчит, свет гаснет или включается режим «сплю»), автозапуск после отключения

питания (настройка BIOS), health-check и оповещения в Telegram, ротация логов.

Прошивка ESP32

- Отправляет события: button_down, button_up, presence_on, presence_off.
- Принимает команды: led_state {idle|greet|listen|think|speak|error|sleep}, led_brightness.
- Встроенные анимации: дыхание в idle, пульс при прослушивании, «бегущая волна» во время раздумья, свет в такт речи (по уровню, который присылает ПК).
- Антидребезг кнопки, heartbeat раз в секунду.

4. Аппаратная часть (для теста на площадке)

Узел	Ориентир для MVP	Что проверить на месте
Мини-ПК	Intel N100/N305, 16 ГБ RAM, SSD 256 ГБ, промышленный или безвентиляторный корпус	Нагрев в шкафу на солнце
Микрофон	Направленный (суперкардиоида/гиперкардиоида) с ветрозащитой на стойке у кнопки, либо USB-массив с DSP (ReSpeaker и аналоги)	Шум, ветер, дистанция до рта 30–60 см
Аудиоинтерфейс	USB-интерфейс с фантомным питанием, если микрофон XLR	Шумы, земляные петли
Динамик + усилитель	Уличный всепогодный динамик (IP65+), усилитель класса D	Разборчивость, зона слышимости, дребезг конструкции
Кнопка	Антивандальная с подсветкой, IP67	Нажатие мокрыми руками, яркость на солнце
Датчик присутствия	mmWave LD2410 (опционально)	Ложные срабатывания от прохожих
Подсветка	Адресная лента + ESP32	Видимость днём
Связь	Кабель или LTE-роутер с внешней антенной	Задержка (ping) и стабильность в пиковые часы
Шкаф	IP54+, вентиляция с фильтром, подогрев/осушение от конденсата	Температура внутри днём
Питание	ИБП на 10–15 мин, УЗО, заземление конструкции (делает электрик)	Скачки напряжения

Интеграция в металлическую конструкцию:

- динамику нужен акустический выход (перфорация или решётка), сплошной металл глушит звук;
- виброизоляция крепления, иначе дребезг;
- микрофон и динамик разнести как можно дальше;
- защита от солёного воздуха: нержавеющий крепёж, конформное покрытие плат, герметичные разъёмы.

5. Этапы и сроки

#	Этап	Длительность	Результат (что принимаем)
0	Исходные данные	3-5 дней	Место и город, питание, интернет, чертежи скульптуры, круг тем, характер персонажа, тексты об авторе и парке
1	Прототип на ноутбуке	1-2 недели	Каркас voice-core, провайдеры Yandex, персонаж, клавиша пробел вместо кнопки. Демо заказчику: голос, характер, качество ответов. Утверждаем голос и персонажа
2	Стенд с «железом»	1-2 недели	Мини-ПК, микрофон, динамик, ESP32 с кнопкой, светом и датчиком. Fallback, лимиты, автозапуск. Прогон 24 часа без сбоев
3	Тест у объекта	2-3 дня	Замеры ветра, шума, эха, связи, нагрева. Фиксируем комплект оборудования и точки монтажа
4	Доводка и админ-панель	1-2 недели	Панель, журнал, расходы, оповещения, эхоподавление (если нужно), тонкая настройка guardrails по реальным вопросам
5	Монтаж и запуск	2-3 дня	Установка, настройка акустики, приёмочная проверка на площадке, инструкция для персонала
6	Пилот	2 недели	Разбор журналов, донастройка промпта и знаний, решение по перебиваниям и режиму без кнопки

Итого до запуска: около 5-8 недель. Этапы 1 и 2 частично идут параллельно с закупкой оборудования.

Этап 1: разбивка задач

1. Каркас проекта, конфиг, логирование.
2. Запись с микрофона ноутбука + VAD.
3. Провайдер STT (SpeechKit v3 streaming).
4. Провайдер LLM (YandexGPT) со стримингом; промпт персонажа из `persona.yaml` и `knowledge.md`.
5. Провайдер TTS со стримингом по предложениям.
6. State machine с клавиатурой вместо кнопки.
7. Замер задержек по этапам, выводим в лог.
8. Набор из 50 тестовых вопросов (обычные, каверзные, провокационные) с автоматическим прогоном текстом и ручной оценкой.

6. Стоимость (статьи, без цифр до выбора моделей)

- **Оборудование:** мини-ПК, аудиотракт, кнопка и ESP32, свет, шкаф, ИБП, роутер.
- **Монтаж:** электрик, металлорботы (акустическое окно, крепления), настройка звука.
- **Эксплуатация в месяц:** интернет; SpeechKit (оплата за секунды распознавания и символы синтеза); LLM (оплата за токены). Точная сумма считается по ожидаемому числу диалогов в день после этапа 1: в прототипе замеряем фактический расход на один диалог.
- **Разработка:** софт, панель, прошивку и инструкции можно сделать с помощью ИИ-ассистента; физический монтаж и финальная настройка звука выполняются на месте.

7. Риски и как их снимаем

Риск	Мера
Ветер и шум мешают распознаванию	Кнопка + направленный микрофон с ветрозащитой + VAD; проверка на этапе 3
Плохая связь	LTE с внешней антенной, офлайн-реплики, мониторинг ping
Долгий ответ, посетитель уходит	Стриминг на всех этапах, короткие ответы, звуковой или световой «задумался»
Провокации, неуместные ответы	Guardrails, запретные темы, журнал и еженедельный разбор на пилоте
Недоступность сервиса или оплаты в регионе	Абстракция провайдеров, запасной LLM (GigaChat)
Перегрев, конденсат, соль	Шкаф с вентиляцией и осушением, безвентиляторный ПК, защита плат
Вандализм	Антивандальная кнопка, микрофон и динамик за решёткой, скрытый шкаф
Перерасход бюджета	Дневной лимит, автоматический офлайн-режим, оповещение
Персональные данные	Аудио не сохраняется, в журнале только текст без идентификаторов, информационная табличка

8. Что нужно от заказчика для старта

1. Место и город установки, фото и чертежи скульптуры (внутренние полости, сервисный доступ).
2. Наличие питания (220 В, мощность) и интернета на точке.
3. Круг тем: только объект и парк или свободное общение.
4. Персонаж: имя, характер, возраст «голоса», манера речи, примеры желаемых ответов.
5. Тексты: об объекте, авторе и парке, частые вопросы посетителей.
6. Часы работы объекта и требования к громкости.
7. Кто оплачивает облачные сервисы (юрлицо для Yandex Cloud) и допустимый месячный бюджет.

9. Дальнейшее развитие (после пилота)

- Перебивание объекта голосом (full duplex, аппаратное эхоподавление).
- Режим без кнопки по ключевому слову («Привет, ...»).
- Несколько языков (en, zh) с автоопределением.
- Офлайн-режим: локальные STT/LLM/TTS (Whisper + локальная LLM + Silero TTS), нужен ПК с GPU и отдельная проверка скорости и качества.
- Статистика: популярные вопросы, пиковые часы, средняя длина беседы.